



Step2 – IMDB Top 1000 데이터 탐색

목표

- Step1에서 만든 `data_array.npy` 불러오기
- 전체 영화 개수 확인
- 영화 평점(`Rate`) 관련 통계 계산
 - 평균 평점
 - 최고 평점
 - 최저 평점
- NumPy 배열 형태와 일부 데이터를 확인

접근 방법

1. NumPy 배열 불러오기

- `.npy` 파일은 NumPy 전용 바이너리 파일
- `allow_pickle=True` 옵션 필요 (dtype=object 배열)

2. 데이터 구조 확인

- 배열 일부 출력 및 `.shape` 확인

3. 전체 영화 개수

- 배열의 행 수 = 영화 개수

4. 평점(Rate) 통계 계산

- 3번째 컬럼(`Rate` , 인덱스 2) 추출
- `float` 타입 변환
- 평균, 최고, 최저 계산

구현 코드

```
import numpy as np

# NumPy 배열 불러오기
data_array = np.load("../04_outputs/data_array.npy", allow_pickle=True)

# 총 영화 개수
total_movies = data_array.shape[0] # NumPy 배열 행 수 = 영화 개수
print("총 영화 개수:", total_movies)

# 평점 (Rate) 관련 통계
# 평점은 배열의 3번째 컬럼 (인덱스 2)
ratings = data_array[:, 2].astype(float) # 평점 컬럼 추출 및 float 변환
ave_rat = np.mean(ratings) # 평점
max_rat = np.max(ratings) # 최고
min_rat = np.min(ratings) # 최저

print(f"평균 평점: {ave_rat:.2f}\n최고 평점: {max_rat}\n최저 평점: {min_rat}")
```

1. `np.load(..., allow_pickle=True)`

- `dtype=object` 배열을 불러올 때 필요
- 문자열과 숫자가 혼합된 배열에 대응

[allow_pickle=True 옵션이 필요한 이유](#)

2. 전체 영화 개수

- `.shape[0]` = 배열 행 수

[.shape란?](#)

3. 평점 컬럼 추출 및 타입 변환

- `data_array[:, 2]` : → 모든 행 선택 `2` → 2번째 열 선택 (0부터 시작, 즉 세 번째 컬럼)
즉, `data_array[:, 2]` 는 모든 영화의 평점(Rate) 컬럼만 추출한 1차원 배열.
- 문자열 형태로 저장되어 있을 수 있으므로 NumPy 배열의 자료형을 강제로 변환하는 메서드 `astype(float)` 필요

4. 평점 통계 계산

- `np.mean()` , `np.max()` , `np.min()` 사용
- 소수점 출력은 `.2f` 으로 깔끔하게 조절 가능

결과

총 영화 개수: 1000
평균 평점: 8.10
최고 평점: 9.3
최저 평점: 8.0

```
총 영화 개수: 1000
평균 평점: 8.1
최고 평점: 9.3
최저 평점: 8.0

종료 코드 0(으)로 완료된 프로세스
```